

Lab 8

1. คำถามวิเคราะห์

- 1. หลังรวมไฟล์ orders มีจำนวนแถวเท่าใด และเหลือกี่แถวหลังลบ duplicate?
- 2. มีแถวที่ customer_id หรือ product_id ไม่พบใน Master Data อย่างละกี่แถว?
- 3. มียอดขายที่ใช้ได้จริงกี่ธุรกรรม และยอดขายสุทธิรวมเท่าใด?
- 4. จังหวัดใดมียอดขายสุทธิสูงสุด?
- 5. หมวดสินค้าใดมียอดขายสุทธิสูงสุด?
- 6. หากสลับลำดับ merge ก่อน cleaning ผลลัพธ์หรือความเชื่อมั่นของข้อมูลเปลี่ยนอย่างไร?

คำตอบคำถามวิเคราะห์ 6 ข้อ

Q1 หลัง concat → 752 แถว | หลัง dedup → 746 แถว (ลบ order_id ซ้ำ 2 + null unit_price 2 + qty≤0 2)

Q2 customer_id ไม่พบใน master = 22 แถว | product_id ไม่พบใน active master = 59 แถว

Q3 ยอดขายที่ใช้ได้จริง = 538 ธุรกรรม | net_sales รวม = 9,012,831.04 บาท

Q4 จังหวัดที่มียอดสูงสุด → กรุงเทพมหานคร (2,334,701 บาท, 133 ออเดอร์)

Q5 หมวดสินค้าที่มียอดสูงสุด → Accessory (2,577,480 บาท, 159 ออเดอร์)

Q6 หากสลับลำดับ merge ก่อน cleaning: (1) discount_pct="5%" ยังไม่แปลงเป็น float ทำให้ merge ไม่ match หรือคำนวณ net_sales ผิด (2) province ที่ยังไม่ standard เช่น "Bangkok" จะแยกกลุ่มจาก "กรุงเทพมหานคร" ทำให้ summary ผิดพลาด (3) duplicate order_id ที่ยังไม่ dedup จะเกิด fan-out หลัง merge ทำให้นับยอดขายซ้ำ — ความเชื่อมั่นในข้อมูลลดลงอย่างมีนัยสำคัญ

Data Quality Report – ก่อนและหลัง Integration

ขั้นตอน	จำนวนแถว	หมายเหตุ
Raw orders (ม.ค. + ก.พ.)	752	concat สองเดือน
หลัง dedup + business rules	746	ลบ 6 แถว (null price, ซ้ำ, qty≤0)
Matched customer & product	667	ตัดออก 79 (ไม่พบใน master)
PAID sales (fact จริง)	538	ยอดขายสุทธิรวม 9,012,831.04 บาท